

**DEPARTAMENTO DE MATEMÁTICAS APLICADAS Y
SISTEMAS**

PREDICCIÓN DE EMOCIONES MEDIANTE APRENDIZAJE AUTOMÁTICO

PROYECTO TERMINAL I

ISAÍ OBED ZURITA PRADO

Asesores:

Dra. Alicia Montserrat Alvarado González

Dr. Antonio López Jaimes

1. Introducción

En la actualidad, la predicción basada en datos se ha convertido en una herramienta fundamental en diversos ámbitos, desde el comercio electrónico hasta los sistemas inteligentes de navegación. Esta capacidad de anticipar comportamientos o respuestas futuras es uno de los pilares del desarrollo tecnológico actual. Dentro de este amplio campo, un área particularmente desafiante y en constante crecimiento es la predicción de emociones humanas.

El presente Proyecto Terminal se centra en esta línea, con el objetivo de desarrollar un sistema capaz de anticipar la respuesta emocional de un usuario en un entorno de toma de decisiones simuladas. En este entorno, el usuario observa a un robot que actúa para alcanzar una meta, y expresa sus emociones en función de lo que percibe, utilizando dos escalas fundamentales: valencia (grado de agrado o desagrado) y arousal (nivel de activación o intensidad emocional).

A partir de estos registros, se entrena un modelo de aprendizaje automático que aprende a reconocer patrones emocionales, con el fin de predecir futuras respuestas emocionales del usuario. Este enfoque no solo tiene aplicaciones en la mejora de la interacción humano-máquina, sino que también abre la puerta al diseño de sistemas más empáticos y adaptativos, capaces de responder en tiempo real al estado afectivo de las personas.

2. Motivación y contexto del problema

Cuando una persona interactúa de forma prolongada con un sistema que requiere evaluar opciones una y otra vez, como sucede al elegir entre distintos tiempos de operación de un robot, es común que experimente fatiga o desinterés. Esta carga cognitiva puede afectar la calidad de sus decisiones. En contextos donde las emociones juegan un papel clave (como la interacción humano-robot), anticiparse a la respuesta emocional del usuario puede hacer la experiencia más fluida, eficiente y natural.

Inspirados en algoritmos como el de recomendación musical de Spotify, que aprenden nuestras preferencias y anticipan qué canciones nos gustarán, este proyecto busca aplicar técnicas similares en un entorno experimental, donde los usuarios interactúan con robots simulados y expresan su reacción emocional en distintas rondas.

La predicción continua trata de estimar valores que van cambiando con el tiempo o conforme avanza una tarea. A diferencia de predecir una sola categoría o número fijo, aquí se necesita que el modelo se adapte e interprete datos que van llegando poco a poco, lo cual es muy útil cuando se trabaja con usuarios en sistemas interactivos.

En el contexto de nuestro proyecto terminal, trabajamos con un sistema de toma de

decisiones donde un usuario evalúa diseños de llegada de un robot en varias rondas, con el objetivo de evaluar el más conveniente en cuanto a tiempo de llegada, riesgo y velocidad. Lo interesante del enfoque es que el usuario no expresa sus preferencias directamente, sino a través de sus emociones, las cuales son medidas mediante dos dimensiones: valencia (qué tan agradable es una emoción) y excitación (qué tan intensa es). El reto es predecir estas emociones conforme el usuario interactúa con los diseños, para que el sistema pueda anticiparse a sus decisiones futuras.

Esto serviría para que el usuario no tenga que estar evaluando diseño por diseño todo el tiempo, lo cual a veces puede ser cansado o repetitivo, ya que en lugar de evaluar cada diseño manualmente en cada ronda, el sistema podría hacer ciertas evaluaciones automáticamente basándose en las emociones ya registradas y sus patrones.

3. Antecedentes

El reconocimiento emocional mediante aprendizaje automático ha sido ampliamente abordado en ámbitos como el análisis de expresiones faciales, la voz o señales fisiológicas. No obstante, en este proyecto se trabaja directamente con las respuestas emocionales subjetivas del usuario, capturadas mediante escalas de valencia (agrado) y arousal (intensidad), lo que representa una fuente distinta y valiosa de datos afectivos.

Existen diversas técnicas de aprendizaje automático para la predicción continua de variables emocionales. Entre las más utilizadas se encuentran algoritmos como Support Vector Machine (SVM), Random Forest, Redes Neuronales Artificiales (RNA) y k-Nearest Neighbors (k-NN). Estas técnicas fueron analizadas considerando aspectos como su precisión, tiempo de entrenamiento, capacidad de generalización y facilidad de implementación. Para facilitar la comparación entre ellas, se sugiere incluir una tabla que resuma sus ventajas y desventajas, lo cual permitiría identificar con mayor claridad cuál se ajusta mejor a las características del problema.

Actualmente, se siguen evaluando estas alternativas con el objetivo de seleccionar la más adecuada para el contexto particular del proyecto. Todas ellas presentan ventajas potenciales que dependen, en gran medida, de la estructura y naturaleza de los datos emocionales recolectados.

4. Planteamiento del problema

La predicción de emociones humanas representa un desafío complejo dentro del campo del aprendizaje automático, debido a la naturaleza subjetiva y dinámica de las respuestas afectivas. Anticipar cómo se sentirá una persona en función de sus elecciones

pasadas puede mejorar significativamente la interacción humano-máquina, especialmente en entornos donde las decisiones se ven influenciadas por el estado emocional del usuario.

En el contexto de este proyecto, se ha observado que los usuarios tienden a mostrar inconsistencias en sus respuestas emocionales conforme avanzan las rondas de selección, lo cual puede deberse al cansancio, a la fatiga cognitiva o a la dificultad de elegir entre opciones similares. Estas variaciones dificultan que el sistema identifique con precisión el diseño ideal para cada usuario.

Ante este panorama, se plantea el siguiente problema:

Este trabajo explora la posibilidad de anticipar las emociones futuras de un usuario dentro de un entorno de toma de decisiones, mediante el uso de modelos de aprendizaje automático entrenados con sus respuestas previas, con el objetivo de asistir al usuario durante el proceso sin interferir en la autenticidad de sus decisiones.

5. Descripción general de la propuesta

El sistema recopilará la información emocional del usuario en cada ronda del experimento, la cual se almacenará en archivos JSON que incluirán la respuesta del usuario en términos de valencia y arousal (a través de sliders), tiempo de respuesta, nivel de riesgo percibido y llegada del robot. Se desarrollará un conjunto de scripts en Python que permitirá extraer, visualizar y organizar estos datos, facilitando la identificación de patrones en la evolución emocional del usuario.

Con base en estos registros, se analizarán múltiples usuarios y rondas, y se contrastarán distintos algoritmos de predicción continua, priorizando aquellos que se ajusten a escenarios con pocas variables, alta subjetividad y conjuntos de datos reducidos. Entre las opciones consideradas, el algoritmo k-NN será uno de los seleccionados por su facilidad de interpretación, buen rendimiento en conjuntos pequeños y su capacidad para capturar similitudes locales sin necesidad de una representación abstracta compleja.

El modelo resultante buscará predecir las emociones del usuario en futuras rondas, utilizando como base su historial emocional. Este conocimiento podrá ser aprovechado para que el sistema proponga o automatice decisiones en nombre del usuario, con el fin de hacer el proceso más eficiente y menos demandante cognitivamente.

6. Objetivos

Objetivo general

Desarrollar un modelo de aprendizaje automático que sea capaz de predecir las emociones de un usuario en términos de valencia y arousal, basado en su historial emocional durante rondas de evaluación de diseños robóticos.

Objetivos específicos

- Diseñar un proceso de extracción y limpieza de datos emocionales a partir de archivos JSON.
- Visualizar la evolución emocional por usuario, identificando patrones por ronda.
- Evaluar y comparar distintos algoritmos de regresión continua para la predicción de emociones.
- Seleccionar el modelo más adecuado y entrenarlo con los datos disponibles.
- Validar la capacidad de generalización del modelo con nuevos usuarios.
- Aplicar el modelo en un entorno simulado para predecir respuestas emocionales, disminuyendo la carga cognitiva del usuario.

Este proyecto no solo busca resolver un problema técnico, sino también aportar una solución empática a una interacción humano-máquina más inteligente, intuitiva y personalizada. La toma de decisiones asistida no es solo una meta computacional, sino un puente hacia una tecnología que comprende mejor a quienes la usan.

7. Tabla comparativa de algoritmos propuestos

En el proceso de diseño del sistema, se consideraron diversos algoritmos de predicción continua con el objetivo de identificar cuál ofrecía el mejor desempeño dentro del contexto particular del proyecto: un conjunto de datos reducido, subjetivo y centrado en respuestas emocionales humanas. Para ello, se realizó un análisis comparativo entre varios métodos de aprendizaje automático comúnmente utilizados en tareas de regresión, evaluando sus principales ventajas y desventajas en función de su precisión, interpretabilidad, requerimientos computacionales y adaptabilidad a datos emocionales. A continuación se

presenta una tabla que resume esta comparación, la cual sirvió como base para la selección del modelo más adecuado.

Cuadro 1: Comparativa de algoritmos de predicción continua

Algoritmo	Funcionamiento	Ventajas	Desventajas
Support Vector Machine (SVM)	Busca un hiperplano óptimo con margen máximo usando funciones <i>kernel</i> para representar relaciones no lineales. En regresión (SVR), ajusta los valores objetivo dentro de un margen ϵ utilizando solo los vectores de soporte [1].	Alta precisión en espacios complejos, uso eficiente de memoria, buena capacidad de generalización con kernels adecuados [1], [3].	Dependiente de la selección de kernel, entrenamiento lento en grandes conjuntos, sensible a valores atípicos y escalado de variables [4], [5].
Random Forest	Conjunto de árboles de decisión entrenados sobre subconjuntos aleatorios del conjunto de datos y características. En regresión, promedia las predicciones de todos los árboles para reducir la varianza [6].	Alta precisión, robusto al sobreajuste, tolerante al ruido, puede estimar importancia de variables [6], [7].	Menor interpretabilidad que un solo árbol, uso intensivo de memoria, más costoso computacionalmente [6], [8].
Red Neuronal Artificial (RNA)	Modelo con capas de neuronas artificiales que ajustan pesos mediante retro-propagación para minimizar el error. Puede modelar relaciones no lineales complejas [9], [10].	Capacidad para modelar patrones complejos, arquitectura flexible para distintos tipos de datos, permite aprendizaje incremental [10], [11].	Requiere muchos datos, difícil de interpretar y ajustar, entrenamiento lento sin hardware especializado [10], [12].
k-Nearest Neighbors (k-NN)	Método basado en instancias que predice un valor continuo promediando los valores de los k vecinos más cercanos según una métrica de distancia, típicamente Euclídea [13], [14].	Fácil de implementar, no necesita entrenamiento, funciona bien con conjuntos pequeños [13].	No escala bien, predicción costosa, sensible a ruido y a la escala de variables [14], [15].

Referencias (Solo de la tabla)

- [1] B. Scholkopf and A. J. Smola, *Learning with Kernels: Support Vector Machines, Regularization, Optimization, and Beyond*. MIT Press, 2002.
- [2] A. Smola and B. Scholkopf, “A tutorial on support vector regression,” *Statistics and Computing*, vol. 14, no. 3, 2004.


- [3] N. Cristianini and J. Shawe-Taylor, *An Introduction to Support Vector Machines and Other Kernel-Based Learning Methods*. Cambridge University Press, 2000.
- [4] M. Mohri, A. Rostamizadeh, and A. Talwalkar, *Foundations of Machine Learning*, 2nd ed. MIT Press, 2018.
- [5] F. Pedregosa et al., “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, vol. 12, 2011.
- [6] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, 2001.
- [7] A. Liaw and M. Wiener, “Classification and regression by randomForest,” *R News*, vol. 2, no. 3, 2002.
- [8] T. K. Ho, “Random decision forests,” in *Proc. of the 3rd International Conference on Document Analysis and Recognition*, 1995.
- [9] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.
- [10] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, “Learning representations by back-propagating errors,” *Nature*, vol. 323, 1986.
- [11] S. Haykin, *Neural Networks and Learning Machines*, 3rd ed. Pearson, 2009.
- [12] Y. LeCun, Y. Bengio, and G. Hinton, “Deep learning,” *Nature*, vol. 521, no. 7553, 2015.
- [13] T. Cover and P. Hart, “Nearest neighbor pattern classification,” *IEEE Trans. Inf. Theory*, vol. 13, no. 1, 1967.
- [14] M. Datar et al., “Locality-sensitive hashing scheme based on p-stable distributions,” in *Proc. 20th Annual Symposium on Computational Geometry*, 2004.
- [15] S. Bhatia, “Survey of Nearest Neighbor Techniques,” *International Journal of Computer Science and Information Security*, vol. 8, no. 2, 2010.

8. Justificación del uso del algoritmo k-NN

Durante las pruebas del sistema, se identificó que conforme los usuarios avanzan en la evaluación de diseños de robots, sus respuestas emocionales (valencia y arousal) se tornan inconsistentes debido a la fatiga o repetición. Para reducir esta carga cognitiva, se optó por implementar un modelo de aprendizaje automático que pudiera anticipar emociones futuras con base en experiencias pasadas.



Clasificador **KNN**



K-Nearest Neighbors

¿Por qué aprendizaje automático?

El aprendizaje automático permite modelar el comportamiento emocional de un usuario y predecir sus reacciones sin requerir interacción constante. Esta capacidad de anticipación hace que el proceso de toma de decisiones sea más ágil y personalizado.

¿Por qué k-NN?

El algoritmo *k-Nearest Neighbors* (k-NN) fue seleccionado por diversas razones:

- No requiere una suposición formal de un modelo matemático, lo cual es ideal para datos subjetivos como emociones.
- Funciona bien con conjuntos de datos pequeños, como los recolectados en este experimento.
- Aprende directamente de ejemplos pasados del mismo usuario, lo que garantiza una adaptación personalizada.
- Es fácil de interpretar y aplicar en sistemas interactivos.

¿Cómo funciona en este proyecto?

1. El sistema guarda los valores de valencia y arousal de rondas anteriores.
2. Cuando se presenta un nuevo diseño de robot, k-NN busca los k ejemplos más similares entre los ya registrados.
3. Promedia sus emociones asociadas y las utiliza para predecir la respuesta emocional esperada.
4. Con esta predicción, el sistema puede automatizar decisiones, reduciendo la necesidad de evaluación constante.

Ventajas en este contexto

- Elimina la necesidad de que el usuario evalúe manualmente cada nuevo diseño.
- Reduce la fatiga y mejora la experiencia del usuario.
- Aprovecha información previa del propio usuario, lo que incrementa la precisión.
- Se adapta a cambios graduales en las emociones a lo largo del tiempo.

Estudio relacionado sobre k-NN y estimación emocional en tiempo real

Un estudio reciente titulado *Affective state estimation based on Russell's model and physiological measurements*, publicado en la revista *Scientific Reports* (2023), propone un sistema para estimar estados afectivos en tiempo real basándose en señales fisiológicas. El estudio adopta el modelo bidimensional de Russell, que define las emociones en un espacio compuesto por valencia (agrado-desagrado) y arousal (activación emocional), exactamente las mismas dimensiones empleadas en nuestro proyecto.

Los investigadores recopilaron datos de señales como ritmo cardíaco, conductancia de la piel y frecuencia respiratoria de 45 participantes mientras estos eran expuestos a distintos estímulos afectivos. A partir de estas mediciones, extrajeron un total de 23 características fisiológicas. Luego, aplicaron el algoritmo *ReliefF* para seleccionar las 13 características más relevantes para estimar valencia y arousal, optimizando así el rendimiento del modelo.

Posteriormente, el estudio comparó diversos algoritmos, incluyendo:

- **k-Nearest Neighbors (k-NN)**
- **Support Vector Machines (SVM)** con kernels gaussiano y cúbico
- **Análisis discriminante lineal (LDA)**

Los resultados indicaron que el algoritmo k-NN no solo ofrecía la mayor precisión promedio en la clasificación de emociones (tanto binaria como multiclase), sino que también destacó por su velocidad, con un tiempo promedio de estimación inferior a los 15 milisegundos. Esta capacidad de respuesta rápida lo hace ideal para sistemas en tiempo real donde se requiere adaptar la experiencia del usuario de forma inmediata según su estado emocional.

Relación con nuestro proyecto

Este estudio proporciona evidencia empírica sólida a favor del uso de k-NN en tareas de predicción emocional, especialmente cuando se trabaja con variables subjetivas como la valencia y el arousal. Aunque nuestro proyecto no se basa en señales fisiológicas sino en respuestas conscientes del usuario expresadas mediante sliders, el principio de predicción rápida y precisa de emociones a partir de datos previos es compartido.

Además, la naturaleza interactiva de nuestro sistema en donde el usuario evalúa distintos diseños en rondas sucesivas, se beneficia directamente de las cualidades del algoritmo k-NN: adaptabilidad, simplicidad y capacidad de generalización con datasets pequeños. El estudio refuerza así nuestra elección

metodológica, demostrando que k-NN no solo es útil por su facilidad de implementación, sino también por su eficacia probada en entornos reales y dinámicos como los que buscamos modelar.

[hyperref](#)

9. Implementación

Toda la implementación de este proyecto se encuentra en la siguiente liga de GitHub:

<https://github.com/isaizurita/emocionesJSON.git>

Conclusiones

Este proyecto terminal abordó el desafío de anticipar el estado emocional de un usuario dentro de un entorno de toma de decisiones simuladas, donde la interacción no se limita a la lógica racional, sino que se ve profundamente influenciada por emociones como el agrado y la intensidad emocional. La incorporación de estas dos dimensiones, extraídas directamente a partir de sliders utilizados por el usuario, permitió modelar una experiencia mucho más cercana a la realidad humana.

El principal objetivo fue desarrollar un sistema que, al reconocer patrones en las emociones previas del usuario, pudiera predecir su reacción futura frente a nuevos diseños de robots. Esta predicción continua, aplicada a cada ronda de evaluación, reduce significativamente la necesidad de evaluaciones manuales y repetitivas, lo que a su vez disminuye la carga cognitiva y mejora la experiencia de uso.

Durante la fase de diseño e implementación, se construyó un flujo de trabajo en Python que permitió extraer, limpiar, organizar y visualizar los datos emocionales. Posteriormente, se evaluaron diversos algoritmos de aprendizaje automático enfocados en regresión y clasificación continua. Entre ellos, se eligió el algoritmo k-Nearest Neighbors (k-NN) por sus ventajas clave: facilidad de interpretación, buen rendimiento con conjuntos de datos pequeños, y su capacidad para generalizar a partir de ejemplos previos del mismo usuario.

El **algoritmo k-NN**, además, fue respaldado por investigaciones recientes que **lo destacan como una de las opciones más eficientes y rápidas para estimación emocional en tiempo real**, incluso en condiciones más complejas como el uso de señales fisiológicas. Esta evidencia científica fortaleció la elección metodológica del proyecto y aportó una base sólida a nuestras decisiones de diseño.

En conjunto, este proyecto representa un primer paso hacia la construcción de sistemas más completos, capaces de adaptar su comportamiento con base en las emociones humanas. Así, será posible comprobar que es posible reducir el esfuerzo mental requerido en procesos repetitivos, creando así experiencias más naturales, personalizadas y centradas en el usuario.

El desarrollo de tecnologías que entiendan y respeten las emociones humanas no solo mejora la interacción hombre-máquina, sino que también abre la puerta a aplicaciones futuras en educación, salud, asistencia social y entretenimiento, donde el estado emocional del usuario debe ser tomado en cuenta para tomar mejores decisiones.

- [1] C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006.
- [2] T. Cover and P. Hart, “Nearest neighbor pattern classification,” *IEEE Transactions on Information Theory*, vol. 13, no. 1, pp. 21–27, 1967.
- [3] R. Cowie, E. Douglas-Cowie, and C. Cox, “Beyond emotion archetypes: Databases for emotion modelling using neural networks,” *Neural Networks*, vol. 18, no. 4, pp. 371–388, 2005.
- [4] R.Cittadini, C.Tamantini, F.Scotto di Luzio, C.Lauretti, L.Zollo, F.Cordella, “Affective state estimation based on Russell’s model and physiological measurements,” *Scientific Reports*, vol. 13, art. 9786, 2023. doi:10.1038/s41598-023-36915-6.